

Q/R/M/C: протокол оценивания на основе постадийной декомпозиции для агентов с памятью

Anonymous submission

Abstract

Метрики, учитывающие только успех, схлопывают качественно различные сбой памяти в единственный скаляр, скрывая, *какой этап* конвейера извлечения за них отвечает. Мы предлагаем протокол оценивания (evaluation protocol): декомпозицию Q/R/M/C — формирование запроса (Query formation), извлечение (Retrieval satisfaction), материализация цели (target Materialization) и завершение (Completion), — операционализированную так, что четыре условные частоты вычислимы из стандартных логов траекторий. Арифметика здесь — цепное правило, и это сделано намеренно: как и в случае precision/recall, ценность заключается в идентифицируемости и в том, что именно декомпозиция позволяет увидеть. Одноагентный случай (MiniGrid, BabyAI): оракульные вмешательства на уровне этапов локализуют задачу, ограниченную извлечением ($0.39 \rightarrow 0.60$ при оракульном извлечении), в отличие от задач, ограниченных нижележащими этапами, а инспекция логов уточняет диагноз — *ранжирование* кандидатов почти оптимально (96.9%), тогда как *генерация* кандидатов отказывает в 91% точек принятия решений: предел накопления памяти. Многоагентный случай (35,640 прогонов, четыре архитектуры обмена, каденция K): предсказанный сдвиг узкого места между материализацией и завершением подтверждён в виде кластерно-устойчивых наклонов (коэффициент Спирмена $-0.53/+0.43$), время до успеха имеет внутренний оптимум при $K=8$, а аннотация провенанса (provenance) даёт механизм — коллапс завершения при быстром обмене концентрируется в логах, опирающихся на чужие свидетельства. Внешне тот же контракт над трассами инструментов инструментует три сторонних агентных стека (OpenAI SDK, LangGraph, AutoGen): сконструированные структурные сбой локализуются одинаково на каждом стеке ($R^*=0$, $C^*=0$ в 20/20), тогда как на чистых задачах сквозной успех фреймворков разбросан в диапазоне 0.50–0.75, и этапы приписывают этот разброс слабой дисциплине первого коммита (first-commitment discipline) при различающихся циклах восстановления. Протокол делает сбой па-

мяти сопоставимыми между символьными, обученными, LLM-, одно- и многоагентными системами.

Введение

Воплощённые, целеобусловленные и LLM-агенты всё чаще извлекают места, объекты и факты *по смыслу* из явной памяти, однако оцениваются почти исключительно сквозным образом (end-to-end): если успех растёт, память признаётся полезной. Две системы с одинаковой долей успеха могут отказывать по совершенно разным причинам — одна вовсе не накапливает пригодных для запросов свидетельств, другая извлекает безупречно и уступает цель напарнику. Настоящая работа предлагает измерительный инструмент, разделяющий такие случаи.

Инструмент — четырёхэтапная декомпозиция выполнения задачи с опорой на память: формирование запроса — **Q** (планировщик выдаёт семантический интент), извлечение — **R** (память возвращает кандидата, соответствующего задаче), материализация цели — **M** (планировщик фиксирует лок на одном кандидате как действенной цели) и завершение — **C** (контроллер достигает её). Записанные как эпизодные события Q^*, R^*, M^*, C^* , они факторизуют завершение семантического пути в условные частоты, оцениваемые по обычным логам траекторий (Определение 1; многоагентное расширение с каналами связи через память и занятость — Определение 2). Аргумент согласованности — цепное правило плюс частотное оценивание, и мы не претендуем на математическую новизну: ровно так же, как разложение ассигасы на precision и recall не добавило математики, но изменило то, что способно видеть общество, вклад состоит в *дисциплине логирования* и в том, что она вскрывает.

Вклад работы.

1. **Протокол.** Операциональные, на уровне логов, определения четырёх этапных событий для одиночных агентов (Определение 1) и коммуницируемых коллективов (Определение 2), с идентифицируемостью при явно сформулированном условном этапно-марковском предположении, а также стресс-тест этого предположения.

2. **Диагнозы, недоступные метрике успеха.** Одно-агентный случай: оракульные вмешательства на уровне этапов и форензика логов относят сбой к *накоплению* памяти, а не к ранжированию. Многоагентный случай: зарегистрированное утверждение об уровне наклонов (Эмпирическое утверждение 1) — быстрый обмен повышает $P(M^*|R^*)$ и понижает $P(C^*|M^*)$ — подтверждено на свипе из 35,640 прогонов, с внутренним оптимумом времени до успеха при $K=8$ и механизмом на уровне провенанса.
3. **Внешняя валидность.** Тот же контракт, определённый единожды над трассами инструментов, инструментирует агентов OpenAI-SDK, LangGraph и AutoGen без адаптации под каждый фреймворк; сконструированные структурные сбой локализируются одинаково на всех стеках, а поведенческие различия между стеками атрибутируются поэтапно.

Границы применимости и не-утверждения. (i) Никакой математической новизны в факторизации нет; вклад — в операционализации. (ii) Эмпирическое утверждение 1 — проверенное наблюдение на уровне наклонов, а не теорема. (iii) Мы не делаем утверждений об условном произведении Φ (монотонном на наших данных); внутренний оптимум живёт на времени до успеха. (iv) Основные субстраты — сеточные миры; проверка в непрерывных состояниях (VMAS) носит ориентировочный характер; LLM-исследования используют локальные модели при скромных n . (v) Идентичность мест в многоагентном случае предполагает общую систему координат; сопутствующая рукопись снимает это предположение.

Протокол Q/R/M/C

Эпизод порождает семантический запрос q (теги required/preferred/penalty); память возвращает кандидатов; планировщик фиксирует лок на одном из них; контроллер исполняет. Четыре события привязаны к логируемым триггерам: Q^* срабатывает при выдаче интента; R^* — когда множество кандидатов содержит кандидата, удовлетворяющего задаче; M^* — при взятии лока на истинной цели; C^* — по достижении. Поэпизодные флаги — дизъюнкции по тикам; условные частоты $P(R^*|Q^*)$, $P(M^*|R^*)$, $P(C^*|M^*)$ — частотные оценки по эпизодам.

Определение 1 (одноагентная оцениваемость, неформально). При условном этапно-марковском свойстве — исход каждого этапа зависит от трассы только через предшествующий этап — завершение семантического пути факторизуется как $P(C^*) = P(Q^*)P(R^*|Q^*)P(M^*|R^*)P(C^*|M^*)$, и каждый сомнительно состоятельно оценивается по логам. Имитационный стресс-тест количественно оценивает смещение оценок при нарушении предположения скрытым конфаундером: $P(M^*|R^*)$ остаётся несмещённой, тогда как $P(C^*|M^*)$ завышается, так что диагнозы, опирающиеся на *контраст* М-С, деградируют плавно (см. дополнение).

Определение 2 (многоагентное расширение, неформально). При N агентах, разделяющих память через пиринговую широкополосную рассылку каждые K тиков, условные множества расширяются двумя каналами связи: общей памятью $M_{-i}^{(K)}$ и занятостью O_{-i} (дефицитные цели потребляются). Те же четыре частоты логируются на каждого агента.

Эмпирическое утверждение 1 (сдвиг узкого места, уровень наклонов). С уменьшением K (ускорением обмена) $P(M^*|R^*)$ растёт — более свежие свидетельства от напарников обеспечивают надёжный коммит, — а $P(C^*|M^*)$ падает — напарники соревнуются за одни и те же цели. Оба утверждения касаются условных частот, а не их произведения.

Интерпретационные прочтения этапов (порядково-теоретическое описание пустого извлечения через соответствие Галуа запрос-объём; описание в терминах options/semi-MDP того, почему оптимумы возникают на метриках, несущих время) намеренно вынесены в дополнение: это линзы, а не результаты.

Одиночный агент: локализация сбоя

На 10-сидовом бенчмарке MiniGrid (семантический поиск воды/отдыха, возврат в целевую область в FourRooms, восстановление после опасности в LavaGapS7; переносимость на BabyAI — в дополнении) сквозной успех скрывает неоднородность: вода и отдых сильны (0.95, 0.93), возврат и восстановление после опасности слабы — причём *по разным причинам*, которые разделяются оракульными вмешательствами на уровне этапов. Замена извлечения оракулом поднимает успех восстановления после опасности $0.39 \rightarrow 0.60$ (задача ограничена извлечением); тот же оракул спасает завершение семантического пути при возврате в целевую область, *не меняя* сквозного успеха (задача ограничена нижележащими этапами). Собственные логи фреймворка затем уточняют атрибуцию: когда кандидаты есть, точность ранжирования составляет 96.9%; но множество кандидатов *пусто* в 91% точек принятия решений. Связывающее ограничение — не выбор среди воспоминаний, а само *накопление* памяти, пригодной для запросов. Это единственное число перенаправило нашу инженерную работу с ранжировщиков на консолидацию — и оно невидимо для оценивания только по успеху.

Обученный baseline с клонированием поведения иллюстрирует тезис о наблюдаемости: конкурентоспособный успех при схлопнутой этапной структуре (нет явного интерфейса запросов/локов), то есть сквозная оптимизация размывает ровно те события, которые аудирует протокол.




Рис. 1: Цикл диагноз→вмешательство→проверка на одноагентном бенчмарке: оракульные вмешательства на уровне этапов поднимают ровно тот этап, на который указывает декомпозиция. Восстановление после опасности ограничено извлечением (оракул-R: 0.39→0.60 сквозного успеха); возврат в целевую область ограничен нижележащими этапами (оракул-R спасает завершение семантического пути, сквозной успех не меняется).

Мультиагентность: память как общий ресурс

Четыре архитектуры обмена над одним символьным субстратом — независимые приватные памяти, общая шина событий, центральный агрегатор со взвешиванием по доверию и пиринговая ширококошечательная рассылка с каденцией $K \in \{1, \dots, 64\}$ — выполняют задачу поиска дефицитной воды ($N \in \{3, 5, 8\}$ агентов, $T \leq N$ целей, три планировки, три плотности опасностей, 40 сидов; 35,640 прогонов). Рисунок 2 показывает этапный профиль каждой архитектуры; извлечение насыщается, и вся дифференциация живёт на звеньях M и C, как и предсказывает Эмпирическое утверждение 1.

Сдвиг узкого места. По пиринговым прогонам коэффициент Спирмена между $P(M^*|R^*)$ и K равен -0.53 (кластерно-устойчивый 95%-й ДИ $[-0.59, -0.47]$ по 81 конфигурационной ячейке), а между $P(C^*|M^*)$ и K равен $+0.43$ ($[+0.37, +0.50]$). Более острая сигнатура — внутрикаденционная: коэффициент Пирсона между двумя звеньями внутри фиксированного K достигает пика -0.61 при $K=4$ и затухает до шума к $K=64$ — узкое место мигрирует между этапами внутри одной и той же конфигурации по мере изменения K . Масштабирование до $N=12$ заостряет сигнатуру (пик -0.70 с миграцией к $K=8$). На среднем времени до успеха этот размен порождает внутренний оптимум при $K=8$; темп консолидации — реальная, настраиваемая ось проектирования. Оракульные вмешательства замыкают цикл: при быстром каденции оракулы-R/M/C последовательно устраняют избыточное время, атрибутируя его переходу $M \leftrightarrow C$.

Механизм — провенанс. Аннотируя каждое M^* долей φ чужих свидетельств в его опорной массе (вычисленной из собственных весов слияния, замороженных в момент лока) и называя локи с $\varphi \geq 0.8$ *warр*-локами: доля *warр* падает с 0.55 при $K=1$ до

0.11 при $K=8$, тогда как локи на собственных свидетельствах завершаются со стабильной частотой 0.26–0.34, а *warр*-локи — ниже 0.05 на всём диапазоне. Коллапс C при быстром обмене концентрируется в страте чужих свидетельств — каденция управляет тем, какая часть коммитов коллектива опирается на свидетельства напарников, и именно эта страта проигрывает гонку за занятость. Та же кривая воспроизводится на непрерывном мосте VMAS (0.72→0.00) и на текстовом LLM-субстрате (0.42→0.08).

Обученные и LLM-коллективы. Baseline CommNet-PPO достигает успеха символьного пиринга (0.667 против 0.65) при структурно вырожденных этапах (его вещественнозначный канал никогда не бывает информативно пустым; R/M схлопываются) — конкурентоспособный успех, нулевая наблюдаемость этапов. Коллектив из трёх LLM-агентов (Llama3.1), разделяющих символьную память, воспроизводит феноменологию на языке: при парном сравнении с baseline без коммуникации на идентичных планировках сырой обмен *снижает* успех $2/3 \rightarrow 1/3$ (гонка за занятость), а децентрализованный протокол резервирования с откатом возвращает часть его ($0.33 \rightarrow 0.42$) при латентности отката $\approx K$. На свипе по бюджету шагов с двумя локальными моделями непрозрачный коллапс успеха ($1.00 \rightarrow 0.00$) разрешается в чистый сбой этапа C ($Q^*=R^*=M^*=1$, $C^*=0$) одинаково для обеих моделей: диагноз структурный, а не модельно-специфичный.

Контракт на сторонних агентных стеках

Работает ли протокол на системах, которые построили не мы? Мы инструментируем три стека — цикл function calling на OpenAI-SDK, ReAct-агента LangGraph и AutoGen — идентичным контрактом, определённым единожды над *трассами инструментов*: эпизодическая бытовая память за инструментами *recall/goto/take*; Q^* — при обращении с запросом, R^* — при атрибуции (возвращённая запись называет предмет в его истинном месте), M^* — при локе уровня эпизода, C^* — при завершении в пределах бюджета инструментов. Четыре варианта конструируют по одному сбою каждый; все предсказания были зарегистрированы до прогонов, и две ревизии семантики событий зафиксированы в регистрации.

Три результата (таблица 1, рис. 4). (1) **Структурные локализации точны и независимы от фреймворка:** нет консолидированного факта $\Rightarrow R^*=0.00$; бюджет ниже необходимого $\Rightarrow C^*=0.00$ при $Q^*=R^*=1$ — 20/20 эпизодов на каждом стеке, без адаптации под фреймворк. (2) **Чистый контроль разделяет стеки, а этапы говорят, чем именно.** Успех на идентичных чистых эпизодах разбросан в диапазоне 0.50–0.75. Лидерборд сообщил бы «разное качество»; этапы показывают общую патологию — дисциплина первого коммита слаба повсюду ($M_1=0.25$ –0.50: первый *goto* часто игнорирует только что извлечённые агентом собственные свидетельства) — плюс разную эконо-




Рис. 2: Условные частоты Q/R/M/C по архитектурам (сверху) и среднее время до успеха (снизу) на свипе из 35,640 прогонов. Общая шина, центральный агрегатор и быстрая пиринговая рассылка ($K \leq 4$) находятся в режиме насыщения M / коллапса C; независимые агенты и медленный пиринг ($K \geq 16$) — в обратном. Время до успеха имеет внутренний минимум при $K=8$ (7.47 против 8.02 у независимых), устойчивый по положению, неглубокий по величине.

Таблица 1: Q/R/M/C на сторонних стеках (20 эпизодов на ячейку). M_1 : первый коммит нацелен на истинное место.

Стек	Вариант	Q^*	R^*	M^*	C^*	M_1
OpenAI SDK	контроль	1.00	1.00	.85	.75	.25
	разрыв консол.	1.00	.00	.50	.40	.25
	уст. неодноз.	1.00	1.00	.90	.30	.25
	жесткий бюджет	1.00	1.00	.25	.00	.25
Lang-Graph	контроль	1.00	1.00	.70	.50	.50
	разрыв консол.	1.00	.00	.20	.15	.10
	уст. неодноз.	1.00	1.00	.65	.60	.50
	жесткий бюджет	1.00	1.00	.10	.00	.10
Auto-Gen	контроль	1.00	1.00	.85	.55	.45
	разрыв консол.	1.00	.00	.30	.20	.15
	уст. неодноз.	1.00	1.00	.50	.45	.35
	жесткий бюджет	1.00	1.00	.15	.00	.15

мику циклов: M уровня эпизода восстанавливается до 0.70–0.85 повторным запросом, а стеки различаются тем, сколько из этого дожидается до завершения (C/M от 0.88 вниз до 0.65). **(3) Устаревший дистрактор притягивает, и неравномерно.** Устаревшая запись захватывает первый коммит в 0.20–0.40 неоднозначных эпизодов, а её цена для завершения специфична для фреймворка (OpenAI SDK: 0.75 $\rightarrow$ 0.30; остальные поглощают крюк). Зареги-

стрированные поведенческие предсказания, предполагавшие чистый контроль, провалились *потому, что сами стеки проваливают чистую задачу на память в 25–50% случаев*, — результат (2), доложенный как зарегистрированные неудачи с механизмами.

Связанные работы

Линии когнитивных и семантических карт мотивируют явную абстракцию мест (Tolman 1948; Gupta et al. 2017; Savinov, Dosovitskiy, and Koltun 2018); целеобусловленный RL обуславливается на цели или эмбединги (Andrychowicz et al. 2017); многоагентный RL изучает обучаемые каналы (Sukhbaatar, Szlam, and Fergus 2016; Foerster et al. 2018) и россипротокоты (Boyd et al. 2006); системы LLM-агентов добавляют явные слои памяти, оцениваемые сквозным образом (Wang et al. 2024; Shinn et al. 2023; Packer et al. 2023; Park et al. 2023; Wu et al. 2023). Протокол ортогонален всем четырём линиям: он не предлагает архитектуру; он делает любую из них поэтапно диагностируемой по логам и даёт проверяемое на этих логам предсказание о каденции на уровне наклонов.

Ограничения

Основные субстраты — сеточные миры; VMAS — ориентировочная проверка в непрерывных состоя-




Рис. 3: Стратификация $P(C^*|M^*)$ по провенансу в зависимости от каденции K (пиринг, ячейки с дефицитом, бутстреп-ДИ с кластеризацией по эпизодам). Доля локов, опирающихся на чужие свидетельства (доля warp, серым), растёт с ускорением обмена, при этом завершение в этой страте (оранжевым) остаётся ниже 0.05, а страта собственных свидетельств (синим) остаётся плоской: коллапс C при быстром обмене сосредоточен в страте чужих свидетельств.

ниях; LLM-исследования используют небольшие локальные модели при скромных n ; идентичность мест между агентами предполагает общую систему координат (конструктивно устранено в сопутствующей рукописи); Эмпирическое утверждение 1 остаётся на уровне наклонов — вывод при порождающей модели сделал бы из него теорему. Полные таблицы, доказательства аргументов оцениваемости, стресстесты предположений, методология размеров эффекта, масштабирование и все файлы зарегистрированных предсказаний — в дополнении.

Заключение

Q/R/M/C превращает «память агента отказала» из скалярного вердикта в локализованный, сопоставимый и порой исправимый диагноз: предел консолидации у одиночного агента, темп обмена с ценой занятости в коллективе, разрыв в дисциплине коммита у готовых агентных стеков. Протокол стоит контракта логирования, а не новой архитектуры — и те же четыре числа читаются на символьных, обученных и LLM-системах.




Рис. 4: Этапные профили трёх сторонних стеков на четырёх сконструированных вариантах (llama3.1, $n=20$ на ячейку). Q и R насыщаются одинаково; структурные сбои дают точные нулевые столбцы на каждом стеке; межфреймворковый разбор живёт в M и C.

Список литературы

- Andrychowicz, M.; Wolski, F.; Ray, A.; Schneider, J.; Fong, R.; Welinder, P.; McGrew, B.; Tobin, J.; Abbeel, P.; and Zaremba, W. 2017. Hindsight Experience Replay. In *NeurIPS*.
- Boyd, S.; Ghosh, A.; Prabhakar, B.; and Shah, D. 2006. Randomized Gossip Algorithms. *IEEE Transactions on Information Theory*, 52(6): 2508–2530.
- Foerster, J.; Farquhar, G.; Afouras, T.; Nardelli, N.; and Whiteson, S. 2018. Counterfactual Multi-Agent Policy Gradients. In *AAAI*.
- Gupta, S.; Davidson, J.; Levine, S.; Sukthankar, R.; and Malik, J. 2017. Cognitive Mapping and Planning for Visual Navigation. In *CVPR*.
- Packer, C.; Fang, V.; Patil, S. G.; Lin, K.; Wooders, S.; and Gonzalez, J. E. 2023. MemGPT: Towards LLMs as Operating Systems. *arXiv preprint arXiv:2310.08560*.
- Park, J. S.; O’Brien, J.; Cai, C. J.; Morris, M. R.; Liang, P.; and Bernstein, M. S. 2023. Generative Agents: Interactive Simulacra of Human Behavior. In *UIST*.
- Savinov, N.; Dosovitskiy, A.; and Koltun, V. 2018. Semi-parametric Topological Memory for Navigation. In *ICLR*.
- Shinn, N.; Cassano, F.; Gopinath, A.; Narasimhan, K.; and Yao, S. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. In *NeurIPS*.
- Sukhbaatar, S.; Szlam, A.; and Fergus, R. 2016. Learning Multiagent Communication with Backpropagation. In *NeurIPS*.
- Tolman, E. C. 1948. Cognitive Maps in Rats and Men. *Psychological Review*, 55(4): 189–208.
- Wang, G.; Xie, Y.; Jiang, Y.; Mandlekar, A.; Xiao, C.; Zhu, Y.; Fan, L.; and Anandkumar, A. 2024. Voyager: An Open-Ended Embodied Agent with Large Language Models. *Transactions on Machine Learning Research*.
- Wu, Q.; Bansal, G.; Zhang, J.; Wu, Y.; Li, B.; Zhu, E.; Jiang, L.; Zhang, X.; Zhang, S.; Liu, J.; Awadallah, A. H.; White, R. W.; Burger, D.; and Wang, C. 2023. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. *arXiv preprint arXiv:2308.08155*.