

# Q/R/M/C: протокол оценивания на основе постадийной декомпозиции для агентов с памятью

Anonymous submission

## Abstract

Метрики, учитывающие только успех, схлопывают качественно различные сбой памяти в единственный скаляр, скрывая, *какой этап* конвейера извлечения за них отвечает. Мы предлагаем протокол оценивания (evaluation protocol): декомпозицию Q/R/M/C — формирование запроса (Query formation), извлечение (Retrieval satisfaction), материализация цели (target Materialization) и завершение (Completion), — операционализированную так, что четыре условные частоты вычислимы из стандартных логов траекторий. Арифметика здесь — цепное правило, и это сделано намеренно: как и в случае precision/recall, ценность заключается в идентифицируемости и в том, что именно декомпозиция позволяет увидеть. Одноагентный случай (MiniGrid, BabyAI): оракульные вмешательства на уровне этапов локализуют задачу, ограниченную извлечением ( $0.39 \rightarrow 0.60$  при оракульном извлечении), в отличие от задач, ограниченных нижележащими этапами, а инспекция логов уточняет диагноз — *ранжирование* кандидатов почти оптимально (96.9%), тогда как *генерация* кандидатов отказывает в 91% точек принятия решений: предел накопления памяти. Многоагентный случай (35,640 прогонов, четыре архитектуры обмена, каденция  $K$ ): предсказанный сдвиг узкого места между материализацией и завершением подтверждён в виде кластерно-устойчивых наклонов (коэффициент Спирмена  $-0.53/+0.43$ ), время до успеха имеет внутренний оптимум при  $K=8$ , а аннотация провенанса (provenance) даёт механизм — коллапс завершения при быстром обмене концентрируется в локах, опирающихся на чужие свидетельства. Внешне тот же контракт над трассами инструментов инструментует три сторонних агентных стека (OpenAI SDK, LangGraph, AutoGen): сконструированные структурные сбой локализуются одинаково на каждом стеке ( $R^*=0$ ,  $C^*=0$  в 20/20), тогда как на чистых задачах сквозной успех фреймворков разбросан в диапазоне 0.50–0.75, и этапы приписывают этот разброс слабой дисциплине первого коммита (first-commitment discipline) при различающихся циклах восстановления. Протокол делает сбой па-

мяти сопоставимыми между символьными, обученными, LLM-, одно- и многоагентными системами.

## Введение

Воплощённые, целеобусловленные и LLM-агенты всё чаще извлекают места, объекты и факты *по смыслу* из явной памяти, однако оцениваются почти исключительно сквозным образом (end-to-end): если успех растёт, память признаётся полезной. Две системы с одинаковой долей успеха могут отказывать по совершенно разным причинам — одна вовсе не накапливает пригодных для запросов свидетельств, другая извлекает безупречно и уступает цель напарнику. Настоящая работа предлагает измерительный инструмент, разделяющий такие случаи.

Инструмент — четырёхэтапная декомпозиция выполнения задачи с опорой на память: формирование запроса — **Q** (планировщик выдаёт семантический интент), извлечение — **R** (память возвращает кандидата, соответствующего задаче), материализация цели — **M** (планировщик фиксирует лок на одном кандидате как действенной цели) и завершение — **C** (контроллер достигает её). Записанные как эпизодные события  $Q^*, R^*, M^*, C^*$ , они факторизуют завершение семантического пути в условные частоты, оцениваемые по обычным логам траекторий (Определение 1; многоагентное расширение с каналами связи через память и занятость — Определение 2). Аргумент согласованности — цепное правило плюс частотное оценивание, и мы не претендуем на математическую новизну: ровно так же, как разложение ассигасы на precision и recall не добавило математики, но изменило то, что способно видеть общество, вклад состоит в *дисциплине логирования* и в том, что она вскрывает.

## Вклад работы.

1. **Протокол.** Операциональные, на уровне логов, определения четырёх этапных событий для одиночных агентов (Определение 1) и коммуницируемых коллективов (Определение 2), с идентифицируемостью при явно сформулированном условном этапно-марковском предположении, а также стресс-тест этого предположения.

2. **Диагнозы, недоступные метрике успеха.** Одно-агентный случай: оракульные вмешательства на уровне этапов и форензика логов относят сбой к *накоплению* памяти, а не к ранжированию. Многоагентный случай: зарегистрированное утверждение об уровне наклонов (Эмпирическое утверждение 1) — быстрый обмен повышает  $P(M^*|R^*)$  и понижает  $P(C^*|M^*)$  — подтверждено на свипе из 35,640 прогонов, с внутренним оптимумом времени до успеха при  $K=8$  и механизмом на уровне провенанса.
3. **Внешняя валидность.** Тот же контракт, определённый единожды над трассами инструментов, инструментирует агентов OpenAI-SDK, LangGraph и AutoGen без адаптации под каждый фреймворк; сконструированные структурные сбой локализируются одинаково на всех стеках, а поведенческие различия между стеками атрибутируются поэтапно.

**Границы применимости и не-утверждения.** (i) Никакой математической новизны в факторизации нет; вклад — в операционализации. (ii) Эмпирическое утверждение 1 — проверенное наблюдение на уровне наклонов, а не теорема. (iii) Мы не делаем утверждений об условном произведении  $\Phi$  (монотонном на наших данных); внутренний оптимум живёт на времени до успеха. (iv) Основные субстраты — сеточные миры; проверка в непрерывных состояниях (VMAS) носит ориентировочный характер; LLM-исследования используют локальные модели при скромных  $n$ . (v) Идентичность мест в многоагентном случае предполагает общую систему координат; сопутствующая рукопись снимает это предположение.

## Протокол Q/R/M/C

Эпизод порождает семантический запрос  $q$  (теги required/preferred/penalty); память возвращает кандидатов; планировщик фиксирует лок на одном из них; контроллер исполняет. Четыре события привязаны к логируемым триггерам:  $Q^*$  срабатывает при выдаче интента;  $R^*$  — когда множество кандидатов содержит кандидата, удовлетворяющего задаче;  $M^*$  — при взятии лока на истинной цели;  $C^*$  — по достижении. Поэпизодные флаги — дизъюнкции по тикам; условные частоты  $P(R^*|Q^*)$ ,  $P(M^*|R^*)$ ,  $P(C^*|M^*)$  — частотные оценки по эпизодам.

**Определение 1** (одноагентная оцениваемость, неформально). При условном этапно-марковском свойстве — исход каждого этапа зависит от трассы только через предшествующий этап — завершение семантического пути факторизуется как  $P(C^*) = P(Q^*)P(R^*|Q^*)P(M^*|R^*)P(C^*|M^*)$ , и каждый сомнительно состоятельно оценивается по логам. Имитационный стресс-тест количественно оценивает смещение оценок при нарушении предположения скрытым конфаундером:  $P(M^*|R^*)$  остаётся несмещённой, тогда как  $P(C^*|M^*)$  завышается, так что диагнозы, опирающиеся на *контраст* М-С, деградируют плавно (см. дополнение).

**Определение 2** (многоагентное расширение, неформально). При  $N$  агентах, разделяющих память через пиринговую широкополосную рассылку каждые  $K$  тиков, условные множества расширяются двумя каналами связи: общей памятью  $M_{-i}^{(K)}$  и занятостью  $O_{-i}$  (дефицитные цели потребляются). Те же четыре частоты логируются на каждого агента.

**Эмпирическое утверждение 1** (сдвиг узкого места, уровень наклонов). С уменьшением  $K$  (ускорением обмена)  $P(M^*|R^*)$  растёт — более свежие свидетельства от напарников обеспечивают надёжный коммит, — а  $P(C^*|M^*)$  падает — напарники соревнуются за одни и те же цели. Оба утверждения касаются условных частот, а не их произведения.

Интерпретационные прочтения этапов (порядково-теоретическое описание пустого извлечения через соответствие Галуа запрос-объём; описание в терминах options/semi-MDP того, почему оптимумы возникают на метриках, несущих время) намеренно вынесены в дополнение: это линзы, а не результаты.

## Одиночный агент: локализация сбоя

На 10-сидовом бенчмарке MiniGrid (семантический поиск воды/отдыха, возврат в целевую область в FourRooms, восстановление после опасности в LavaGapS7; переносимость на BabyAI — в дополнении) сквозной успех скрывает неоднородность: вода и отдых сильны (0.95, 0.93), возврат и восстановление после опасности слабы — причём *по разным причинам*, которые разделяются оракульными вмешательствами на уровне этапов. Замена извлечения оракулом поднимает успех восстановления после опасности  $0.39 \rightarrow 0.60$  (задача ограничена извлечением); тот же оракул спасает завершение семантического пути при возврате в целевую область, *не меняя* сквозного успеха (задача ограничена нижележащими этапами). Собственные логи фреймворка затем уточняют атрибуцию: когда кандидаты есть, точность ранжирования составляет 96.9%; но множество кандидатов *пусто* в 91% точек принятия решений. Связывающее ограничение — не выбор среди воспоминаний, а само *накопление* памяти, пригодной для запросов. Это единственное число перенаправило нашу инженерную работу с ранжировщиков на консолидацию — и оно невидимо для оценивания только по успеху.

Обученный baseline с клонированием поведения иллюстрирует тезис о наблюдаемости: конкурентоспособный успех при схлопнутой этапной структуре (нет явного интерфейса запросов/локов), то есть сквозная оптимизация размывает ровно те события, которые аудирует протокол.




Рис. 1: Цикл диагноз→вмешательство→проверка на одноагентном бенчмарке: оракульные вмешательства на уровне этапов поднимают ровно тот этап, на который указывает декомпозиция. Восстановление после опасности ограничено извлечением (оракул-R: 0.39→0.60 сквозного успеха); возврат в целевую область ограничен нижележащими этапами (оракул-R спасает завершение семантического пути, сквозной успех не меняется).

## Мультиагентность: память как общий ресурс

Четыре архитектуры обмена над одним символьным субстратом — независимые приватные памяти, общая шина событий, центральный агрегатор со взвешиванием по доверию и пиринговая ширококошечательная рассылка с каденцией  $K \in \{1, \dots, 64\}$  — выполняют задачу поиска дефицитной воды ( $N \in \{3, 5, 8\}$  агентов,  $T \leq N$  целей, три планировки, три плотности опасностей, 40 сидов; 35,640 прогонов). Рисунок 2 показывает этапный профиль каждой архитектуры; извлечение насыщается, и вся дифференциация живёт на звеньях M и C, как и предсказывает Эмпирическое утверждение 1.

**Сдвиг узкого места.** По пиринговым прогонам коэффициент Спирмена между  $P(M^*|R^*)$  и  $K$  равен  $-0.53$  (кластерно-устойчивый 95%-й ДИ  $[-0.59, -0.47]$  по 81 конфигурационной ячейке), а между  $P(C^*|M^*)$  и  $K$  равен  $+0.43$  ( $[+0.37, +0.50]$ ). Более острая сигнатура — внутрикаденционная: коэффициент Пирсона между двумя звеньями внутри фиксированного  $K$  достигает пика  $-0.61$  при  $K=4$  и затухает до шума к  $K=64$  — узкое место мигрирует между этапами внутри одной и той же конфигурации по мере изменения  $K$ . Масштабирование до  $N=12$  заостряет сигнатуру (пик  $-0.70$  с миграцией к  $K=8$ ). На среднем времени до успеха этот размен порождает внутренний оптимум при  $K=8$ ; темп консолидации — реальная, настраиваемая ось проектирования. Оракульные вмешательства замыкают цикл: при быстром каденции оракулы-R/M/C последовательно устраняют избыточное время, атрибутируя его переходу  $M \leftrightarrow C$ .

**Механизм — провенанс.** Аннотируя каждое  $M^*$  долей  $\varphi$  чужих свидетельств в его опорной массе (вычисленной из собственных весов слияния, замороженных в момент лока) и называя локи с  $\varphi \geq 0.8$  *warр*-локами: доля *warр* падает с 0.55 при  $K=1$  до

0.11 при  $K=8$ , тогда как локи на собственных свидетельствах завершаются со стабильной частотой 0.26–0.34, а *warр*-локи — ниже 0.05 на всём диапазоне. Коллапс C при быстрым обмене концентрируется в страте чужих свидетельств — каденция управляет тем, какая часть коммитов коллектива опирается на свидетельства напарников, и именно эта страта проигрывает гонку за занятость. Та же кривая воспроизводится на непрерывном мосте VMAS (0.72→0.00) и на текстовом LLM-субстрате (0.42→0.08).

**Обученные и LLM-коллективы.** Baseline CommNet-PPO достигает успеха символьного пиринга (0.667 против 0.65) при структурно вырожденных этапах (его вещественнозначный канал никогда не бывает информативно пустым; R/M схлопываются) — конкурентоспособный успех, нулевая наблюдаемость этапов. Коллектив из трёх LLM-агентов (Llama3.1), разделяющих символьную память, воспроизводит феноменологию на языке: при парном сравнении с baseline без коммуникации на идентичных планировках сырой обмен *снижает* успех  $2/3 \rightarrow 1/3$  (гонка за занятость), а децентрализованный протокол резервирования с откатом возвращает часть его ( $0.33 \rightarrow 0.42$ ) при латентности отката  $\approx K$ . На свипе по бюджету шагов с двумя локальными моделями непрозрачный коллапс успеха ( $1.00 \rightarrow 0.00$ ) разрешается в чистый сбой этапа C ( $Q^*=R^*=M^*=1, C^*=0$ ) одинаково для обеих моделей: диагноз структурный, а не модельно-специфичный.

## Контракт на сторонних агентных стеках

Работает ли протокол на системах, которые построили не мы? Мы инструментируем три стека — цикл function calling на OpenAI-SDK, ReAct-агента LangGraph и AutoGen — идентичным контрактом, определённым единожды над *трассами инструментов*: эпизодическая бытовая память за инструментами *recall/goto/take*;  $Q^*$  — при обращении с запросом,  $R^*$  — при атрибуции (возвращённая запись называет предмет в его истинном месте),  $M^*$  — при локе уровня эпизода,  $C^*$  — при завершении в пределах бюджета инструментов. Четыре варианта конструируют по одному сбою каждый; все предсказания были зарегистрированы до прогонов, и две ревизии семантики событий зафиксированы в регистрации.

Три результата (таблица 1, рис. 4). (1) **Структурные локализации точны и независимы от фреймворка:** нет консолидированного факта  $\Rightarrow R^*=0.00$ ; бюджет ниже необходимого  $\Rightarrow C^*=0.00$  при  $Q^*=R^*=1$  — 20/20 эпизодов на каждом стеке, без адаптации под фреймворк. (2) **Чистый контроль разделяет стеки, а этапы говорят, чем именно.** Успех на идентичных чистых эпизодах разбросан в диапазоне 0.50–0.75. Лидерборд сообщил бы «разное качество»; этапы показывают общую патологию — дисциплина первого коммита слаба повсюду ( $M_1=0.25$ –0.50: первый *goto* часто игнорирует только что извлечённые агентом собственные свидетельства) — плюс разную эконо-




Рис. 2: Условные частоты Q/R/M/C по архитектурам (сверху) и среднее время до успеха (снизу) на свипе из 35,640 прогонов. Общая шина, центральный агрегатор и быстрая пиринговая рассылка ( $K \leq 4$ ) находятся в режиме насыщения M / коллапса C; независимые агенты и медленный пиринг ( $K \geq 16$ ) — в обратном. Время до успеха имеет внутренний минимум при  $K=8$  (7.47 против 8.02 у независимых), устойчивый по положению, неглубокий по величине.

Таблица 1: Q/R/M/C на сторонних стеках (20 эпизодов на ячейку).  $M_1$ : первый коммит нацелен на истинное место.

| Стек       | Вариант        | $Q^*$ | $R^*$ | $M^*$ | $C^*$ | $M_1$ |
|------------|----------------|-------|-------|-------|-------|-------|
| OpenAI SDK | контроль       | 1.00  | 1.00  | .85   | .75   | .25   |
|            | разрыв консол. | 1.00  | .00   | .50   | .40   | .25   |
|            | уст. неодноз.  | 1.00  | 1.00  | .90   | .30   | .25   |
|            | жёсткий бюджет | 1.00  | 1.00  | .25   | .00   | .25   |
| Lang-Graph | контроль       | 1.00  | 1.00  | .70   | .50   | .50   |
|            | разрыв консол. | 1.00  | .00   | .20   | .15   | .10   |
|            | уст. неодноз.  | 1.00  | 1.00  | .65   | .60   | .50   |
|            | жёсткий бюджет | 1.00  | 1.00  | .10   | .00   | .10   |
| Auto-Gen   | контроль       | 1.00  | 1.00  | .85   | .55   | .45   |
|            | разрыв консол. | 1.00  | .00   | .30   | .20   | .15   |
|            | уст. неодноз.  | 1.00  | 1.00  | .50   | .45   | .35   |
|            | жёсткий бюджет | 1.00  | 1.00  | .15   | .00   | .15   |

мику циклов: M уровня эпизода восстанавливается до 0.70–0.85 повторным запросом, а стеки различаются тем, сколько из этого дожидается до завершения ( $C/M$  от 0.88 вниз до 0.65). **(3) Устаревший дистрактор притягивает, и неравномерно.** Устаревшая запись захватывает первый коммит в 0.20–0.40 неоднозначных эпизодов, а её цена для завершения специфична для фреймворка (OpenAI SDK: 0.75  $\rightarrow$  0.30; остальные поглощают крюк). Зарегистрированные поведенческие предсказания, предпо-

лагавшие чистый контроль, провалились *потому, что сами стеки проваливают чистую задачу на память в 25–50% случаев*, — результат (2), должный как зарегистрированные неудачи с механизмами.

## Связанные работы

Линии когнитивных и семантических карт мотивируют явную абстракцию мест (Tolman 1948; Gupta et al. 2017; Savinov, Dosovitskiy, and Koltun 2018); целеобусловленный RL обуславливается на цели или эмбединги (Andrychowicz et al. 2017); многоагентный RL изучает обучаемые каналы (Sukhbaatar, Szlam, and Fergus 2016; Foerster et al. 2018) и россип-протоколы (Boyd et al. 2006); системы LLM-агентов добавляют явные слои памяти, оцениваемые сквозным образом (Wang et al. 2024; Shinn et al. 2023; Packer et al. 2023; Park et al. 2023; Wu et al. 2023). Протокол ортогонален всем четырём линиям: он не предлагает архитектуру; он делает любую из них поэтапно диагностируемой по логам и даёт проверяемое на этих логах предсказание о каденции на уровне наклонов.

## Ограничения

Основные субстраты — сеточные миры; VMAS — ориентировочная проверка в непрерывных состояниях; LLM-исследования используют небольшие локальные модели при скромных  $n$ ; идентичность мест




Рис. 3: Стратификация  $P(C^*|M^*)$  по провенансу в зависимости от каденции  $K$  (пиринг, ячейки с дефицитом, бутстреп-ДИ с кластеризацией по эпизодам). Доля локов, опирающихся на чужие свидетельства (доля warp, серым), растёт с ускорением обмена, при этом завершение в этой страте (оранжевым) остаётся ниже 0.05, а страта собственных свидетельств (синим) остаётся плоской: коллапс  $C$  при быстром обмене сосредоточен в страте чужих свидетельств.

между агентами предполагает общую систему координат (конструктивно устранено в сопутствующей рукописи); Эмпирическое утверждение 1 остаётся на уровне наклонов — вывод при порождающей модели сделал бы из него теорему. Полные таблицы, доказательства аргументов оцениваемости, стресстесты предположений, методология размеров эффекта, масштабирование и все файлы зарегистрированных предсказаний — в дополнении.

### Заключение

Q/R/M/C превращает «память агента отказала» из скалярного вердикта в локализованный, сопоставимый и порой исправимый диагноз: предел консолидации у одиночного агента, темп обмена с ценой занятости в коллективе, разрыв в дисциплине коммита у готовых агентных стеков. Протокол стоит контракта логирования, а не новой архитектуры — и те же четыре числа читаются на символьных, обученных и LLM-системах.




Рис. 4: Этапные профили трёх сторонних стеков на четырёх сконструированных вариантах (llama3.1,  $n=20$  на ячейку). Q и R насыщаются одинаково; структурные сбои дают точные нулевые столбцы на каждом стеке; межфреймворковый разбор живёт в M и C.

### Список литературы

- Andrychowicz, M.; Wolski, F.; Ray, A.; Schneider, J.; Fong, R.; Welinder, P.; McGrew, B.; Tobin, J.; Abbeel, P.; and Zaremba, W. 2017. Hindsight Experience Replay. In *NeurIPS*.
- Boyd, S.; Ghosh, A.; Prabhakar, B.; and Shah, D. 2006. Randomized Gossip Algorithms. *IEEE Transactions on Information Theory*, 52(6): 2508–2530.
- Foerster, J.; Farquhar, G.; Afouras, T.; Nardelli, N.; and Whiteson, S. 2018. Counterfactual Multi-Agent Policy Gradients. In *AAAI*.
- Gupta, S.; Davidson, J.; Levine, S.; Sukthankar, R.; and Malik, J. 2017. Cognitive Mapping and Planning for Visual Navigation. In *CVPR*.
- Packer, C.; Fang, V.; Patil, S. G.; Lin, K.; Wooders, S.; and Gonzalez, J. E. 2023. MemGPT: Towards LLMs as Operating Systems. *arXiv preprint arXiv:2310.08560*.
- Park, J. S.; O’Brien, J.; Cai, C. J.; Morris, M. R.; Liang, P.; and Bernstein, M. S. 2023. Generative Agents: Interactive Simulacra of Human Behavior. In *UIST*.
- Savinov, N.; Dosovitskiy, A.; and Koltun, V. 2018. Semi-parametric Topological Memory for Navigation. In *ICLR*.
- Shinn, N.; Cassano, F.; Gopinath, A.; Narasimhan, K.; and Yao, S. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. In *NeurIPS*.
- Sukhbaatar, S.; Szlam, A.; and Fergus, R. 2016. Learning Multiagent Communication with Backpropagation. In *NeurIPS*.
- Tolman, E. C. 1948. Cognitive Maps in Rats and Men. *Psychological Review*, 55(4): 189–208.
- Wang, G.; Xie, Y.; Jiang, Y.; Mandlekar, A.; Xiao, C.; Zhu, Y.; Fan, L.; and Anandkumar, A. 2024. Voyager: An Open-Ended Embodied Agent with Large Language Models. *Transactions on Machine Learning Research*.
- Wu, Q.; Bansal, G.; Zhang, J.; Wu, Y.; Li, B.; Zhu, E.; Jiang, L.; Zhang, X.; Zhang, S.; Liu, J.; Awadallah, A. H.; White, R. W.; Burger, D.; and Wang, C. 2023. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. *arXiv preprint arXiv:2308.08155*.